VoiceCaster 使用手册

把文字变成能听的东西：旁白、对话、课件讲解。

全部在本机跑，不联网，不按字计费。这份手册按「你打开它想干什么」来排，
不是按代码结构排——想找哪个功能直接跳。

目录

1. 五分钟上手
2. 它由什么组成
3. 声库：先有声音
4. 朗读：一段文字变一段音频
5. 剧本：多角色对话
6. PPT 讲解：课件变有声
7. 两种"拧语气"的办法
8. 快捷键
9. 常见问题
10. 它不做什么

一、五分钟上手

第一次（Apple 芯片 Mac）：

```
sh run-mac.sh
```

它会检查三个服务：小户（千问 `127.0.0.1:3910`）、中户（小米 `:3900`）和主服务（`:7864`），缺哪个拉哪个，好了自动开界面。主服务现在两秒就起来——大户（Vox）改成用到才装了。

之后：双击 `VoiceCaster.app`。

顺序永远是：声库挑声音 → 朗读 / 剧本 / PPT 做事 → 导出。

> 为什么是这个顺序：三个做内容的页面都从声库拿声音。声库里没有的人，

> 那三处就选不到。

二、它由什么组成

```
你的文字 ──► 剧本解析 / 朗读投递 ──► 逐句合成 ──► 拼接 ──► 音频 / 带声课件
                          │
                          └── 声库：官方九条 + 你自己捏的、克隆的
```

四个可以换的引擎（名字是拟人化的，下拉里就写这几个）：

名字	模型	干什么	代价
小户 · 奋斗青年	千问 TTS 1.7B	中文主力：讲课、朗读、演戏	常驻 6.1 G，每句几秒
中户 · 留学生	小米 OmniVoice	只接**外文稿**（646 种语言）	常驻 0.6 G，用时约 4 G
大户 · 方言地头蛇	VoxCPM2	**方言**，和千问联合演戏	用时才装，12 G，闲置 10 分钟自动卸
戏骨	IndexTTS 2.5	更细的情绪（短素材更像）	24 G，按需叫醒，约两分钟

分工是自动的：中文 → 小户；外文 → 中户；方言 → 大户。
演戏时普通话小户念、方言大户念，同一场戏里自动分。
想全都换掉，用页面右上角的「全部用」下拉。

内存保底：同时最多两个「重」引擎（小户 6.1 G、大户 12 G、戏骨 24 G）。
装第三个之前先卸最久没用的；装完如果可用内存会低于 8 G，就不装并提示。
右上角有一行小字：现在谁在内存里、还剩多少。

三、声库：先有声音

打开就在这一页。上面是**官方九条**，下面是**我的声音**。

官方九条

千问自带的九个嗓子，不用克隆就能用：薇薇安、塞雷娜、付叔、瑞恩、艾登、小野安娜（日语）、素熙（韩语）、埃里克（四川话）、迪兰（北京话）。

点卡片上的「▶ 试听」**秒出**——因为九句话是预先录好的音频，不是现场合成。（现场合成要等四秒左右。）

我的声音

三种来源：

- **克隆**：录一段你自己的声音（10–30 秒干净单人说话），存进来
- **捏的**：写一句描述（"中年男人，声音干、有点累，不笑"），一次出三条候选
- **导入**：从官方九条里收进来的

每张卡片右上角的「⋯」

菜单项	干什么	注意
改名字	名字是剧本里认人的依据	改了以后剧本要跟着改
方言	填了以后，这段话交给大户（Vox）用方言念	没装 Vox 就不起作用
换照片	换成你自己的图	58 像素圆形，白边会被裁掉
收进「我的声音」	把官方音色变成你自己的卡	之后能改名、配方言、换照片、删

> **克隆的一个坑**：克隆模型必须同时给它「参考录音说了什么」。
> 第一次用会自动转写一遍，会慢几十秒，之后存在卡片里就不慢了。

四、朗读：一段文字变一段音频

适合：读故事、有声书、把一篇文章念出来。

1. 把文字贴进上面的框，点「投递到朗读框」
2. 在「旁白」下拉里选声音（官方九条 + 你的声音都在里面）
3. 点「生成朗读」

生成完会出现播放器和「↓ 下载整段 wav」。

这里最值钱的一个功能

在正文里选中几个字，右键，可以只给这几个字加语气。
比如整段平稳叙述，只有"他压低声音"这半句要变，就选它。

还能在任意位置**插停顿**。这些标记会画在文字上：加过语气的片段会高亮，
停顿处出现一个 ⏸ 小牌子。

五、剧本：多角色对话

剧本格式

一条规矩：每行「名字：台词」。 冒号右边才念。

```
阿达：我今天只需要一段干净的贝斯 MIDI。
阿诺：交给我就对啦！全自动一站式搞定。
（语音提示：偏快，尾音上扬）
大实话：全自动生成的成品，AI 率百分之百。
```

- `【音效】`、`（情绪）` 会自动剥掉，不念
- 整行被括号包住 = 提示行，不念，但会附加到下一句上
- 分段线（`—— 第一场 ——`）会变成「排演这场」

流程

1. 贴剧本 → 点「读剧本」
2. 系统自动把名字对上声库里的人。**对不上的会标红**，不会悄悄用错嗓子
3. 点「排演」，整本跑完拼成一条
4. 哪句不对，点那句旁边的「重念这句」，只重做那一句

和朗读一样的标记

选中几个字 → 右键 → 加语气；不选字右键 → 在光标处插停顿。
整段排演和单句重念都认这些标记。

对视频打点

如果这段要配画面：加载一个视频（只用来对时间，原视频不存），
播到位置按「打点」，导出的清单里就会写这一句的时间点。

六、PPT 讲解：课件变有声

1. 导入 `.pptx`（在 App 里走系统文件面板）
2. 系统从**备注**里抽讲稿、自动拆句
3. 拆出来的句子可以改、可以删——这是给讲课留的余地
4. 选声音、选格式（mp3 / m4a / wav）、选语速
5. 生成

出来三样东西：

- 每一页一个音频
- 一个**嵌好声音、带播放键**的 pptx
- 一整包的音频

> **为什么用备注写讲稿**：备注本来就是给你自己看的，写多少都不影响观众看到的页面。
> 这套流程就是把「你写给自己的字」变成「你说给观众的话」。

七、两种"拧语气"的办法

整句：右键 → 给这句加说话声音

弹窗里可以手写一句话，还有两个拉杆（语速、力度）。适合整句定调。

片段：选中几个字 → 右键

只改这几个字。适合一句话里有一次转折。

这套指令是稳定的，不是碰运气。 实测同一句：

指令	时长	响度	音高
不加	2.96 秒	0.089	227 Hz
「压低声音，用气声」	3.44 秒	0.073	186 Hz
「非常高兴，笑着说话」	2.24 秒	0.098	298 Hz

同一条指令连跑三次，参数完全一致。

但要知道限度：**它证明"变了、方向对"，证明不了"好听"。** 那个只能靠耳朵。

八、快捷键

键	干什么
⌘R	重新载入界面
⌘Z / ⇧⌘Z	撤销 / 重做
⌘C / ⌘V / ⌘A	拷贝 / 粘贴 / 全选
⌘+ / ⌘− / ⌘0	放大 / 缩小 / 实际大小
⌘Q	退出

九、常见问题

点试听报「千问服务没起来（3910）」
语音服务没在跑。App 会自己拉起它；手动跑的话先起 `tts_server.py`。

剧本读出来名字对不上
声库里没有这个人。去声库收一个，或者把剧本里的名字改成已有的。

整段排演听着断断续续
标记拆得太碎。每个片段是独立合成的，拼起来会有换气感。把标记合并一下。

克隆出来的不像
参考录音要干净：单人、无背景音乐、10—30 秒、别离麦克风太近（有喷麦）。

方言没生效
方言现在**自动**：声音上配了方言就交给大户（Vox），不用管引擎选的是谁。
还是没反应的话，看 Vox 服务在不在（`:3900` 之外它是本程序自己装的，第一次用要等十几秒）。

下载没反应
如果你在用浏览器打开，那是网页的限制。用 App，它会弹保存面板。

十、它不做什么

写清楚比写着好听有用：

- **不修音高、不填词、不做音乐**——它只处理"说话"
- **不做实时**——一句几秒，不是直播工具
- **不代替你判断**——语气对不对、这段像不像人话，永远由你定
- **不联网**——所有声音都在本机算，也就没有"云端更好听"这回事